ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO BÀI TẬP E1–E3

Học sâu và ứng dụng trong thị giác máy tính — CO5085

Học kỳ	HK261 (2026–2027)
Giảng viên	Lê Thành Sách, Nguyễn Quốc Minh
Nhóm	<điền mã nhóm / họ tên 2 thành viên>
Dữ liệu	MNIST (28×28, 10 lớp)
Ngày hoàn thành	31/10/2026

Toàn bộ số liệu trong báo cáo sinh ra từ các script trong repo (E1/run_all.py, E2/run_all.py, E3/run_all.py); seed, cấu hình và log được lưu cùng kết quả.

Mục lục

1. Giới thiệu và thiết lập chung **3**

2. E1 — Phân loại ảnh: softmax, MLP, CNN **3**

2.1. Kiến trúc . . . 3

2.2. Kết quả . . . 3

2.3. Phân tích lỗi . . . 4

3. E2 — Transformer: MSA và tokenization **6**

3.1. Multi-Head Self-Attention . . . 6

3.2. Các cách lấy token . . . 6

3.3. Kết quả . . . 6

4. E3 — LSTM/GRU trên chuỗi ảnh **9**

4.1. Ý tưởng và cách biểu diễn chuỗi . . . 9

4.2. Kết quả và so sánh với baseline . . . 9

5. Kết luận **10**

6. Phụ lục: tái lập **11**

Khai báo sử dụng công cụ AI . . . 11

1. Giới thiệu và thiết lập chung

Báo cáo trình bày ba bài tập E1–E3 trên cùng một tập dữ liệu nhỏ là MNIST: 60.000 ảnh huấn luyện (chia 50.000 train / 10.000 validation theo seed 42) và 10.000 ảnh test chính thức. Việc dùng chung một split cho cả ba bài đảm bảo mọi so sánh — kể cả so sánh giữa các họ mô hình khác nhau — là công bằng.

Ảnh được chuẩn hoá với mean 0,1307 và std 0,3081 (số liệu chuẩn của MNIST) và **không** dùng augmentation, để chênh lệch kết quả phản ánh kiến trúc chứ không phải may mắn của phép biến đổi dữ liệu. Mọi mô hình huấn luyện bằng vòng lặp viết tay (forward → loss → backward → optimizer.step), optimizer Adam, batch 128, và lưu lại *metrics.json* cùng *history.csv* cho từng lần chạy.

Thành phần	Giá trị
Dữ liệu	MNIST 28×28, 1 kênh, 10 lớp
Split	50.000 train / 10.000 val / 10.000 test (seed 42)
Tiền xử lý	chuẩn hoá mean=0,1307 std=0,3081; không augmentation
Optimizer / loss	Adam; CrossEntropyLoss trên logits
Batch / seed	128 / 42
Phần cứng	Intel i5-9300H, NVIDIA GTX 1650 4 GB, PyTorch 2.5.1

Bảng 1. Thiết lập thí nghiệm dùng chung cho cả ba bài.

2. E1 — Phân loại ảnh: softmax, MLP, CNN

2.1. Kiến trúc

Ba mô hình tăng dần về khả năng biểu diễn. **Softmax** chỉ có một phép biến đổi tuyến tính trên vector ảnh đã flatten, tương đương việc học 10 “template” và chọn template khớp nhất — vì vậy nó bị chặn trên bởi giới hạn của một bộ phân loại tuyến tính. **MLP** thêm hai lớp ẩn với ReLU và dropout, tăng đáng kể capacity. **CNN** khai thác hai giả định đúng với ảnh: tính cục bộ (pixel gần nhau mới liên quan) và tính bất biến dịch (một nét vẽ ở góc này hay góc kia đều là cùng một đặc trưng), nhờ chia sẻ trọng số theo vị trí.

Mô hình	Cấu trúc	Tham số
Softmax	Flatten 784 → Linear(784, 10)	7.850
MLP	784 → 256 → 128 → 10 (ReLU, dropout 0,2)	235.146
CNN	4 khối conv 3×3 + BN + ReLU, 2 max-pool, head FC 128	468.010

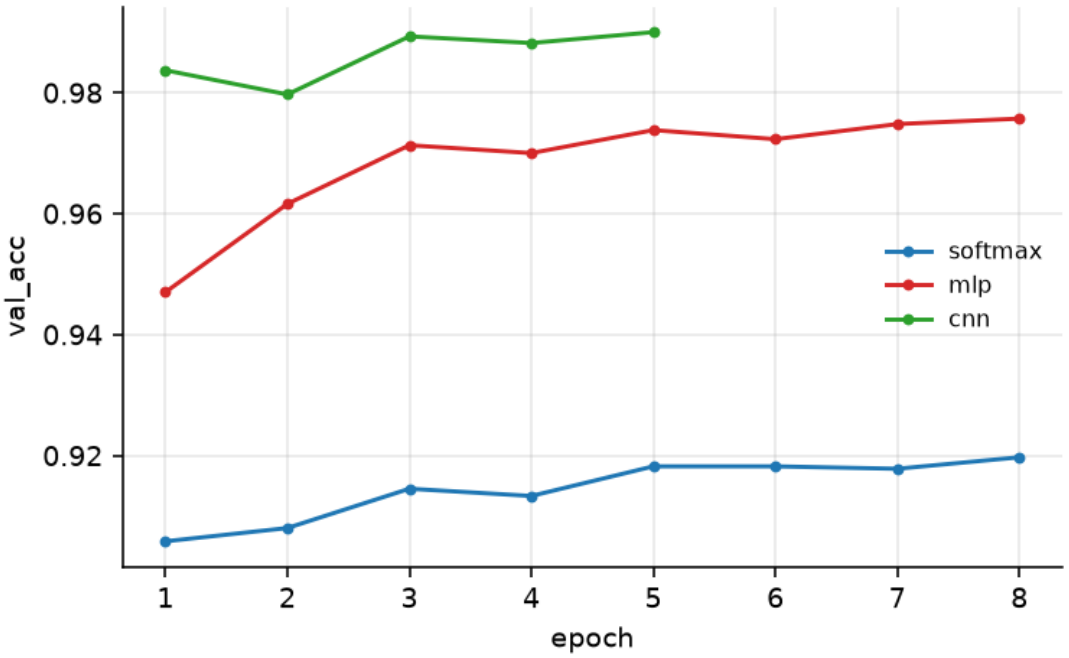
Bảng 2. Ba kiến trúc của E1.

2.2. Kết quả

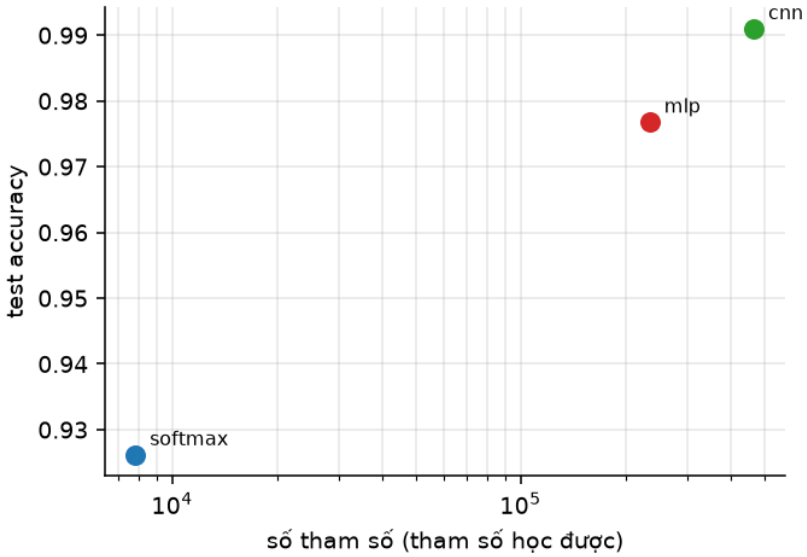
Mô hình	Tham số	Val acc	Test acc	Test loss	Thời gian
softmax	7,850	91.97%	92.62%	0.2680	42 s
mlp	235,146	97.57%	97.68%	0.0778	51 s
cnn	468,010	99.00%	99.10%	0.0293	55 s

Bảng 3. Kết quả E1 trên tập test (10.000 ảnh).

Thứ tự xếp hạng đúng như dự đoán từ lý thuyết: softmax 92.62% < MLP 97.68% < CNN 99.10%. Đáng chú ý là CNN chỉ nhiều tham số gấp đôi MLP nhưng giảm lỗi tương đối gần 60% — phần lớn lợi ích đến từ *inductive bias* (conv + chia sẻ trọng số) chứ không từ việc tăng số tham số. Mô hình tốt nhất là **cnn**.



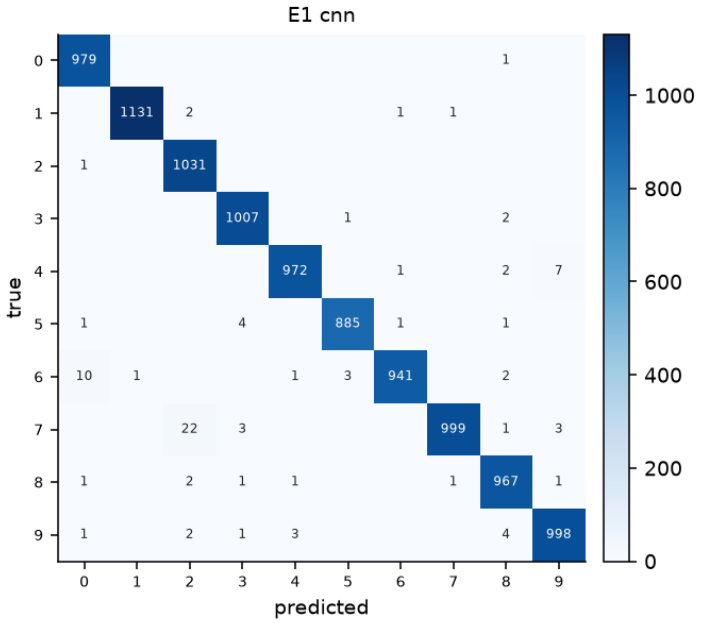
Hình 1. Đường cong validation accuracy của ba mô hình qua các epoch.



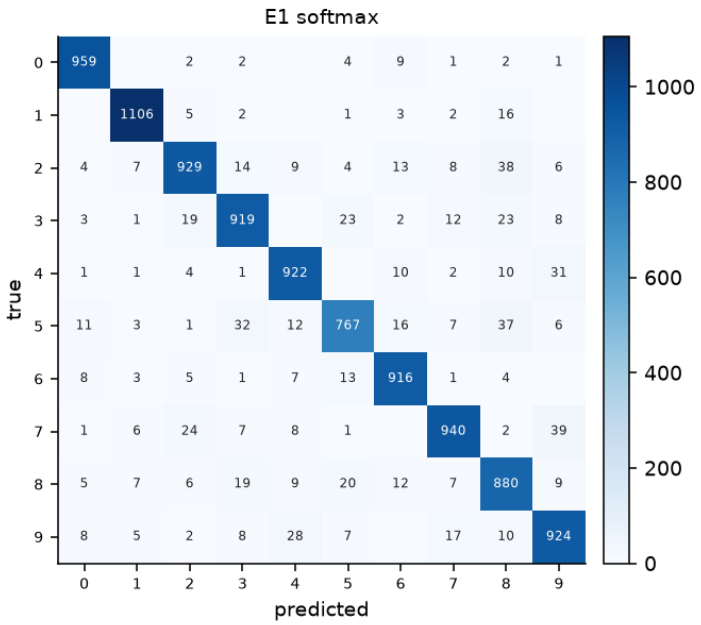
Hình 2. Test accuracy theo số tham số (thang log).

2.3. Phân tích lỗi

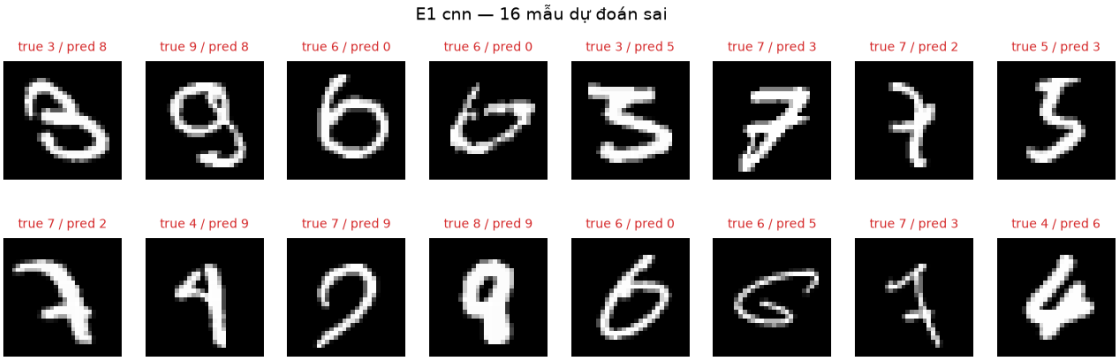
Confusion matrix cho thấy lỗi của softmax tập trung ở các cặp chữ số có nét tương đồng khi nhìn như một chồng pixel (3–5, 4–9, 7–9). CNN giảm mạnh các nhầm lẫn này vì nó học được đặc trưng cục bộ như nét cong kín của số 9 hay nét ngang của số 7. Mẫu dự đoán sai còn lại phần lớn là ảnh mờ, viết ẩu hoặc bị cắt nét — tức là lỗi dữ liệu chứ không phải lỗi kiến trúc.



Hình 3. Confusion matrix của CNN trên tập test.



Hình 4. Confusion matrix của softmax — lỗi lan rộng hơn nhiều so với CNN.



Hình 5. 16 mẫu CNN dự đoán sai (nhãn thật / dự đoán).

3. E2 — Transformer: MSA và tokenization

3.1. Multi-Head Self-Attention

MSA được viết lại từ các phép toán cơ bản (Linear, einsum, softmax, ghép head), không dùng *nn.MultiheadAttention*. Với đầu vào $X \in \mathbb{R}^{B\times N\times d}$: chiếu ra Q, K, V; tính điểm tương đồng đã scale; softmax theo trục key; lấy tổng có trọng số của V; ghép H head rồi chiếu ra output:

$$Q = XW_Q,\ K = XW_K,\ V = XW_V\ ;\ head_h = softmax(Q_hK_h^T/\sqrt{d_k})V_h\ ;\ MSA(X) = concat(head_{1..H})W_O$$

Hệ số $1/\sqrt{d_k}$ giữ phương sai của tích vô hướng bằng 1: nếu không, với d_k lớn, softmax rơi vào vùng bão hoà, gradient gần 0 và mô hình không học được. Đây cũng là lỗi hay gặp nhất khi tự viết.

d	Số head	N	Sai khác output	Sai khác attention	Có mask
128	4	50	8.9e-08	3.0e-08	8.9e-08
64	2	29	7.5e-08	3.7e-08	8.9e-08
96	3	16	1.0e-07	4.5e-08	8.9e-08

Bảng 4. Kiểm chứng MSA tự viết khớp nn.MultiheadAttention khi copy trọng số.

Với cùng bộ trọng số, hai bản cho cùng output với sai khác lớn nhất **1.0e-07** — sai số số học thuần tuý của phép cộng dấu phẩy động. Kết quả này cả khi bật mask, nên có thể khẳng định bản tự viết là đúng đặc tả.

3.2. Các cách lấy token

Ảnh 28×28 không có token tự nhiên như câu chữ, nên cách chia token là một lựa chọn thiết kế có ảnh hưởng trực tiếp: càng nhiều token thì chi phí attention $O(N^2d)$ càng lớn, nhưng mỗi token chứa ít thông tin hơn. Ba cách được triển khai: chia lưới patch 4×4 (49 token, mỗi token 16 chiều), lấy mỗi hàng ảnh làm một token (28 token, 28 chiều), và dùng CNN stem rút feature map 7×7 (49 token, 64 chiều). Mỗi chuỗi được bọc thêm một token CLS và một positional embedding học được, vì bản thân attention không có khái niệm thứ tự.

3.3. Kết quả

Tokenize	MSA	Số token	Tham số	Test acc	s/epoch
patch	manual	50	275,210	67.86%	17.4
patch	torch	50	275,210	69.57%	17.8
row	manual	29	274,058	85.43%	21.1
row	torch	29	274,058	89.19%	14.3
cnnstem	manual	50	300,266	82.05%	20.2
cnnstem	torch	50	300,266	90.63%	21.1

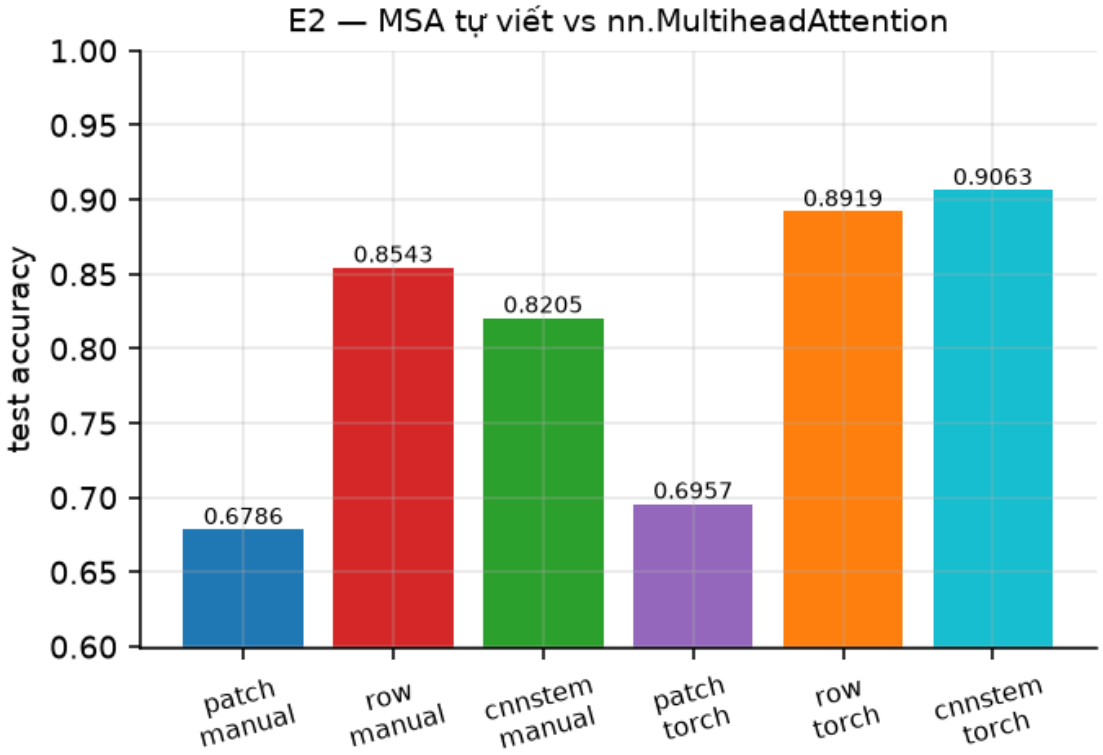
Bảng 5. Kết quả E2: 3 cách tokenize × 2 bản MSA (dim 128, depth 2, 4 head, 4 epoch).

Bản tự viết đạt trung bình 78.45% so với 83.13% của nn.MultiheadAttention. Chênh lệch 4.7 điểm này **không phải** sai lệch toán học — Bảng 4 đã cho thấy hai bản trùng khớp tới 10^{-7} khi dùng chung trọng số. Nó đến từ khởi tạo khác nhau: bản PyTorch gộp ba phép chiếu thành một tensor nên thứ tự sinh số ngẫu nhiên khác bản tự viết, và với chỉ 4 epoch thì mức dao động đó lên tới vài điểm. Về tốc độ, bản tự viết chậm hơn (19.6 so với 17.7 s/epoch) do ba phép chiếu riêng thay vì một phép gộp và không dùng kernel tối ưu.

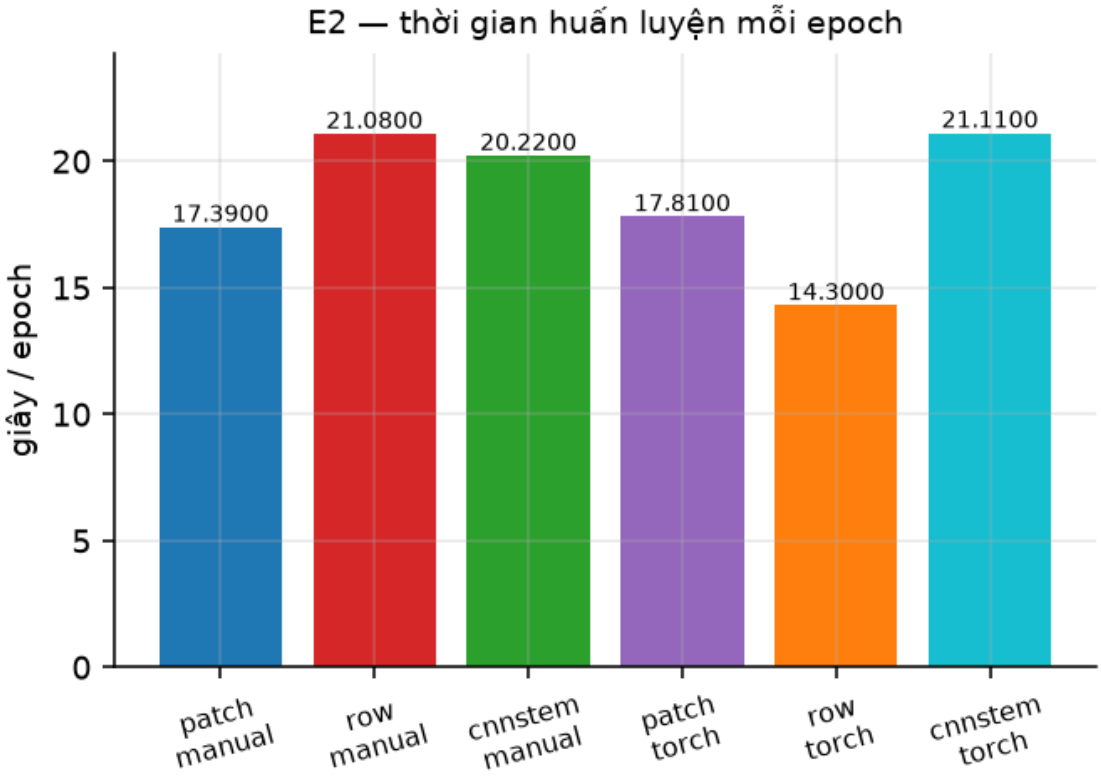
Ba cách tokenize cho kết quả **rất khác nhau**: patch 68.71%, row 87.31%, cnnstem 86.34% — chênh lệch tới 18.6 điểm phần trăm, lớn hơn nhiều so với chênh lệch do đổi bản MSA (4.7 điểm). Nguyên nhân nằm

ở độ sâu: encoder chỉ có 2 block, nghĩa là mỗi token chỉ được trộn thông tin với các token khác hai lần. Với patch 4×4, mỗi token là 16 pixel thô và mô hình phải vừa học đặc trưng cục bộ vừa học cách tổ hợp — quá nhiều việc cho hai lớp attention. Token theo hàng đã chứa sẵn 28 điểm ảnh có cấu trúc nên dễ hơn; CNN stem đưa vào chuỗi những đặc trưng đã tích chập (trường tiếp nhận 5×5) nên đạt kết quả cao nhất. Kết luận: với encoder nông, phần lớn việc trích đặc trưng phải do tokenizer đảm nhiệm.

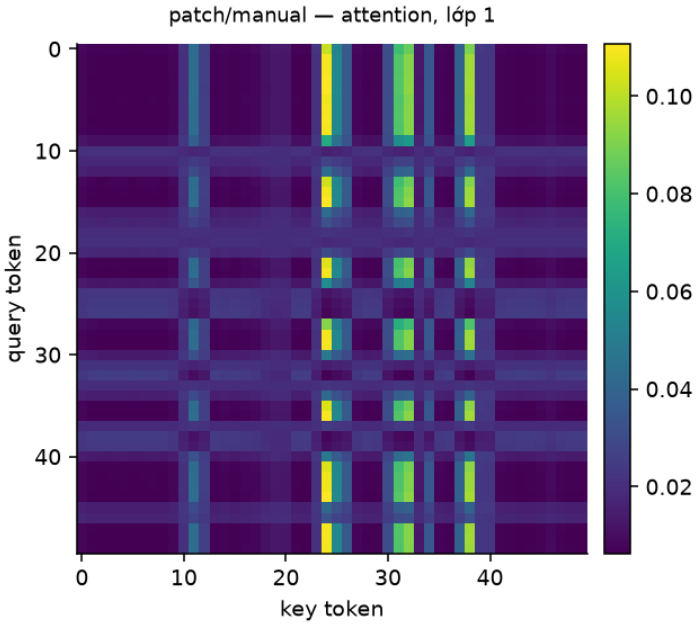
Kiểm tra thêm (tái lập được bằng `--epochs 12`): patch/manual huấn luyện 12 epoch chỉ đạt 69,9% test — tức mô hình bị chặn bởi độ sâu chứ không phải ngân sách epoch. Đây cũng là lý do các ViT thực tế dùng depth 12–24 thay vì 2.



Hình 6. Test accuracy: MSA tự viết vs nn.MultiheadAttention theo từng cách tokenize.



Hình 7. Thời gian huấn luyện mỗi epoch của hai bản MSA.



Hình 8. Bản đồ attention của block đầu (head có phân bố nhọn nhất) với tokenize patch: một vài patch giữ vai trò "key" chính, các patch còn lại gần như bị bỏ qua.

4. E3 — LSTM/GRU trên chuỗi ảnh

4.1. Ý tưởng và cách biểu diễn chuỗi

Ảnh không phải chuỗi tự nhiên, nên E3 là bài toán *chọn cách nhìn*: biến ảnh thành dãy token sao cho thứ tự mang thông tin. Ba cách được thử: mỗi hàng ảnh là một bước thời gian (T=28, F=28), mỗi cột là một bước (T=28, F=28), và mỗi patch 4×4 theo thứ tự quét từng hàng patch (T=49, F=16). Mô hình dùng *nn.LSTM* hoặc *nn.GRU* một lớp, hidden 128, lấy hidden state ở bước cuối để phân loại.

LSTM giải quyết vấn đề tiêu biến gradient bằng cell state cộng dồn ($c_t = f \times c_{t-1} + i \times g$): đạo hàm theo c_{t-1} chỉ còn nhân với cổng f, nên gradient có "đường cao tốc" đi ngược thời gian thay vì bị nhân liên tiếp với ma trận trọng số như RNN thuần. GRU gộp hai cổng còn một, ít tham số hơn khoảng 25% và thường tương đương trên chuỗi ngắn như MNIST.

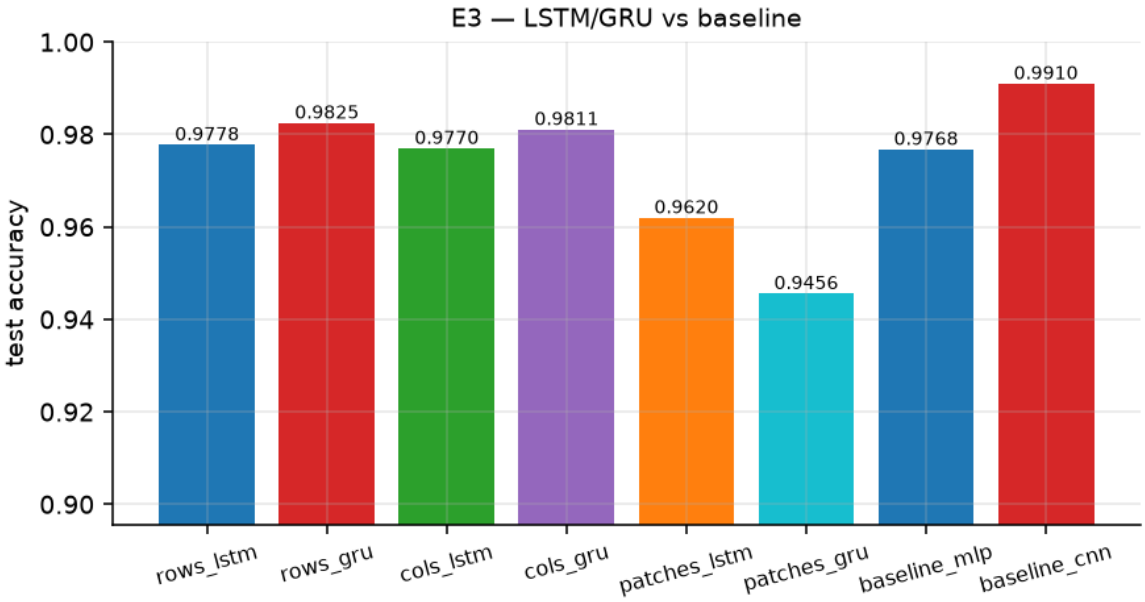
4.2. Kết quả và so sánh với baseline

Biểu diễn	Cell	Tham số	Test acc	s/epoch
rows	lstm	82,186	97.78%	10.6
rows	gru	61,962	98.25%	11.3
cols	lstm	82,186	97.70%	11.3
cols	gru	61,962	98.11%	10.2
patches	lstm	76,042	96.20%	11.9
patches	gru	57,354	94.56%	11.1
baseline MLP	—	235,146	97.68%	6.4
baseline CNN	—	468,010	99.10%	11.0

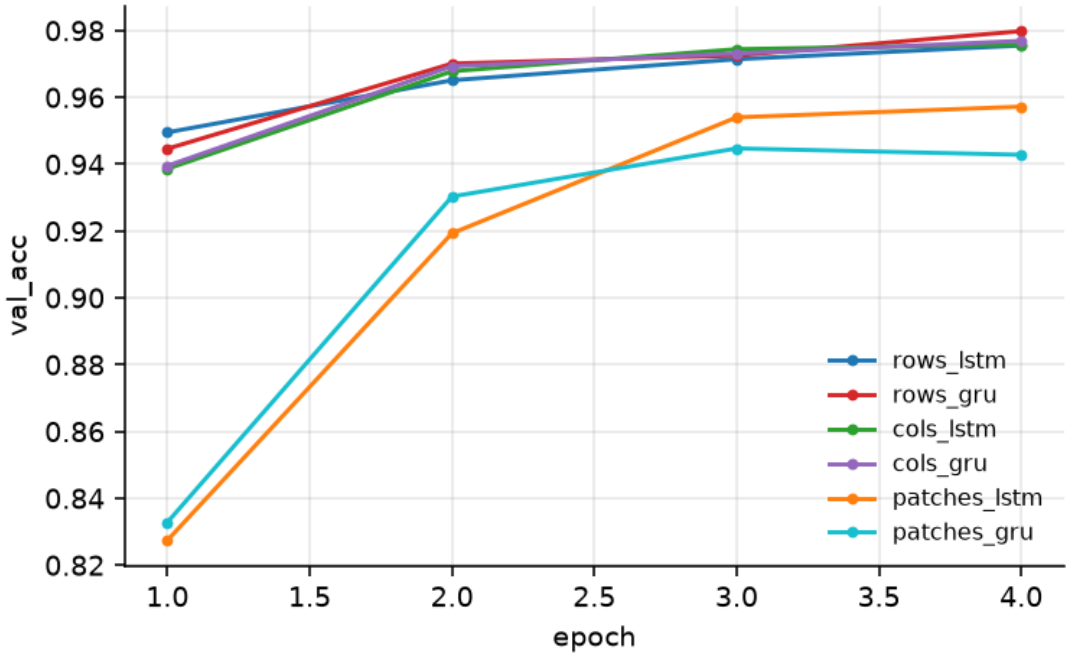
Bảng 6. E3: LSTM/GRU trên ba cách biểu diễn, so với baseline E1 trên cùng split.

Cấu hình tốt nhất là **rows/gru** với 98.25%. Cả LSTM và GRU đều vượt xa MLP nhưng vẫn thấp hơn CNN — kết quả này không phải thất bại mà là thông tin: MNIST gần như không có phụ thuộc đường dài, nên lợi thế của mô hình hồi quy không có đất phát huy, trong khi CNN có inductive bias đúng với ảnh và tính toán song song tốt hơn nhiều.

Để kiểm tra mô hình có thực sự dùng thứ tự hay chỉ cộng các hàng lại, ta đảo ngẫu nhiên thứ tự hàng ở đầu vào của *rows_lstm* đã huấn luyện: accuracy giảm từ 97.78% xuống 11.22% (-86.56 điểm phần trăm). Mức giảm này cho thấy mô hình thực sự khai thác thông tin thứ tự, chứ không chỉ là một bộ tổng hợp không gian.



Hình 9. Test accuracy của LSTM/GRU so với baseline MLP và CNN.



Hình 10. Đường cong validation accuracy của sáu cấu hình LSTM/GRU.

5. Kết luận

• **Kiến trúc phù hợp quan trọng hơn số tham số.** CNN 468 nghìn tham số đạt 99.10% trong khi MLP 235 nghìn tham số chỉ đạt 97.68%; khác biệt nằm ở giả định về cấu trúc ảnh, không ở capacity.

• **Tự viết attention là kiểm chứng được.** Bản MSA viết tay cho output trùng với nn.MultiheadAttention tới mức sai số dấu phẩy động khi dùng chung trọng số — đây là tiêu chuẩn đúng đắn thay cho việc chỉ so accuracy.

• **Tokenization là lựa chọn thiết kế có giá.** Với encoder chỉ 2 block, ba cách chia token lệch nhau tới hàng chục điểm phần trăm: tokenizer nào làm sẵn nhiều việc trích đặc trưng hơn thì kết quả tốt hơn. Số token đồng thời quyết định chi phí $O(N^2d)$.

• **Mô hình hồi quy không thắng trên dữ liệu không có phụ thuộc dài.** LSTM/GRU học được thứ tự (thí nghiệm đảo hàng chứng minh điều đó) nhưng vẫn kém CNN trên MNIST — chọn đúng công cụ cho đúng cấu trúc dữ liệu quan trọng hơn việc dùng mô hình "hiện đại" hơn.

6. Phụ lục: tái lập

Toàn bộ kết quả sinh lại được bằng ba lệnh, mỗi lệnh ghi kết quả vào *E*/results/*:

```
python E1/run_all.py
python E2/run_all.py
python E3/run_all.py
python reports/build_report.py
```

Mỗi lần chạy lưu *metrics.json* (cấu hình, số tham số, accuracy, thời gian, confusion matrix), *history.csv* (loss/accuracy từng epoch) và các hình PNG. Seed cố định 42 cho cả ba bài; split dữ liệu được tạo bằng generator có seed nên danh sách ảnh trong train/val không đổi giữa các lần chạy.

Khai báo sử dụng công cụ AI

Theo yêu cầu mục 1.6 của đề, nhóm khai báo phạm vi sử dụng công cụ AI: *<điền chính xác những gì đã dùng — ví dụ: gợi ý cấu trúc thư mục, rà soát lỗi shape, hình thức trình bày báo cáo>*. Toàn bộ số liệu trong báo cáo do nhóm tự chạy và kiểm chứng; nhóm chịu trách nhiệm giải thích từng đoạn code khi được hỏi.