ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO BÀI TẬP LỚN A2

Học sâu và ứng dụng trong thị giác máy tính — CO5085

Học kỳ	HK261 (2026–2027)
Giảng viên	Lê Thành Sách, Nguyễn Quốc Minh
Sinh viên	Dương Gia An — MSSV 2470293
Hình thức	Cá nhân
Dữ liệu	Pascal VOC 2012 (21 lớp)
Ngày hoàn thành	05/11/2026

Mục lục

1. A2 — Phân đoạn ngữ nghĩa trên Pascal VOC 2012 và phân tích SegFormer **3**

1.1. Bài toán và dữ liệu 3

1.2. Phân tích paper: SegFormer (NeurIPS 2021) 3

1.3. Pipeline và kết quả 3

2. Kết luận **5**

3. Phụ lục: tái lập **5**

Khai báo sử dụng công cụ AI 5

1. A2 — Phân đoạn ngữ nghĩa trên Pascal VOC 2012 và phân tích SegFormer

1.1. Bài toán và dữ liệu

A2 yêu cầu một bài toán thị giác không phải phân loại ảnh thuần. Bài làm chọn **phân đoạn ngữ nghĩa 21 lớp trên Pascal VOC 2012** (1.464 ảnh train / 1.449 val), metric **mIoU** và Dice — đây là bài toán dự đoán dày, khác bản chất với phân loại ở A1, và nối tiếp mạch CNN-vs-Transformer sang một miền mới. Máy chủ gốc của VOC không truy cập được từ mạng của máy này, nên dữ liệu được lấy qua mirror HuggingFace.

1.2. Phân tích paper: SegFormer (NeurIPS 2021)

Xie và cộng sự, *SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers*, NeurIPS 2021 (arXiv:2105.15203). Ba ý tưởng chính:

• **Encoder Transformer phân cấp** trả về đặc trưng đa tỉ lệ (1/4 … 1/32), thay vì một tỉ lệ duy nhất.

• **Bỏ positional encoding**, thay bằng Mix-FFN có conv 3×3 — tránh phải nội suy mã vị trí khi độ phân giải test khác train, vốn là nguồn giảm chất lượng của ViT trong segmentation.

• **Decoder MLP nhẹ**: gộp đặc trưng các tầng rồi chiếu bằng MLP, không dùng decoder nặng.

Thí nghiệm trong paper: SegFormer-B4 đạt 50,3% mIoU trên ADE20K với 64M tham số; B5 đạt 84,0% mIoU trên Cityscapes val. **Hạn chế** được khai thác trong báo cáo: paper đánh giá trên tập lớn có pretrain ImageNet-1k, chưa khảo sát vùng dữ liệu ít như VOC 2012 (~1,5k ảnh) — nơi mà lợi thế của kiến trúc Transformer có thể bị pretrain chi phối hoàn toàn.

1.3. Pipeline và kết quả

Ba biến thể được cài đặt để tách hai yếu tố thường bị trộn lẫn — **kiến trúc** (CNN vs Transformer) và **pretrain** (có vs không): U-Net tự viết (1,9M tham số, train từ đầu), DeepLabV3-ResNet50 (42M, trọng số COCO/VOC có sẵn 21 lớp) và SegFormer-B0 (3,7M, encoder ImageNet-1k + ADE20K, đúng kiến trúc của paper đang phân tích). Ảnh 256×256, CrossEntropyLoss bỏ qua nhãn 255, AdamW.

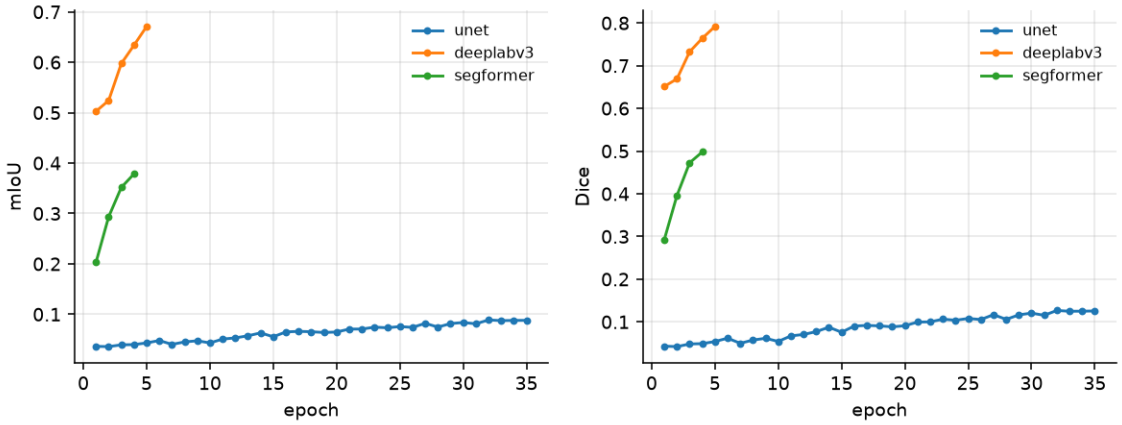
Mô hình	Pretrain	Tham số	mIoU	Dice	Pixel acc	s/epoch
unet	không	1,927,669	8.88%	12.67%	75.70%	116
deeplabv3	COCO + VOC	42,004,074	67.11%	79.18%	91.96%	555
segformer	ImageNet + ADE20K	3,719,541	37.85%	49.79%	86.28%	176

Bảng 11. Kết quả A2 trên VOC 2012 val.

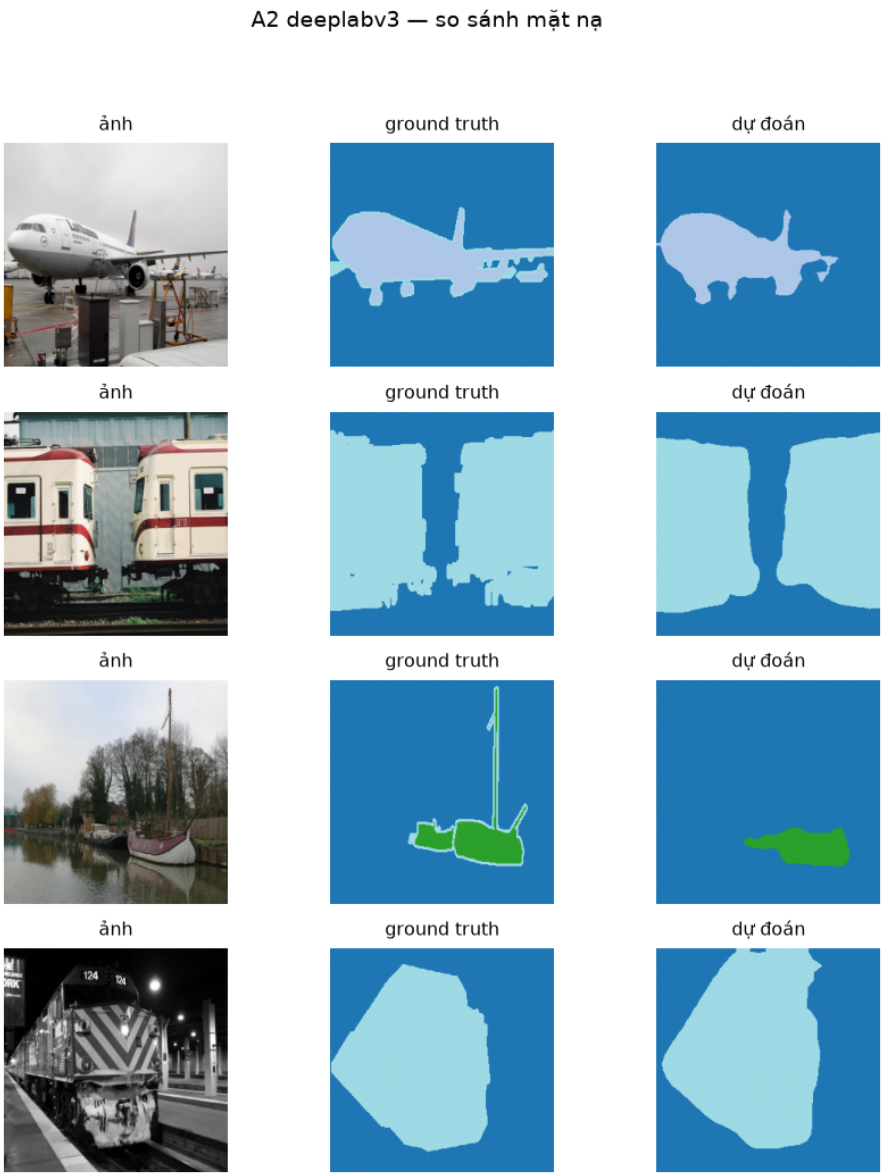
deeplabv3 đạt mIoU 67.11%. Ngay epoch đầu DeepLabV3 đã ở mức 50,3% vì trọng số VOC có sẵn đúng 21 lớp — phần lớn khoảng cách đến từ *pretrain*, không phải từ kiến trúc. SegFormer-B0 nhỏ hơn 11× nhưng sau 4 epoch chỉ đạt 37.85% và nhanh hơn 3.1× mỗi epoch. Điều này khớp với hạn chế của paper đã nêu: trên tập nhỏ, encoder phân cấp của SegFormer cần nhiều epoch hơn để bù lại việc head phân loại phải học lại từ đầu cho 21 lớp VOC.

Về baseline U-Net train từ đầu: VOC 2012 có ~92% pixel là nền, nên CrossEntropyLoss thuần có cực tiểu tầm thường là "đoán toàn nền" và mô hình mắc kẹt ở mIoU ~3,7%. Hai lần sửa đã thử: trọng số lớp nghịch tần suất (không ổn định) và loss CE + Dice (giữ được, dùng cho kết quả dưới đây). Để chắc chắn lỗi không nằm ở kiến trúc, một phép kiểm tra overfit 2 ảnh được chạy (*A2/check_overfit.py*): sau 80 bước, mIoU trên chính 2 ảnh đó đạt 71,5% và pixel accuracy 99,4% — tức kiến trúc và loss học được, giới hạn nằm ở số epoch so với ngân sách GPU.

Kết quả U-Net sau 35 epoch (CE + Dice, lr 0.0005): mIoU 8.88%, Dice 12.67%, pixel accuracy 75.70%. Con số này thấp hơn nhiều so với hai mô hình pretrained, nhưng nó đo đúng điều cần đo: với ~1.500 ảnh huấn luyện và 35 epoch, một CNN tự viết chưa thể cạnh tranh với đặc trưng đã học sẵn từ ImageNet/COCO.



Hình 14. A2 — mIoU và Dice theo epoch.



Hình 15. A2 — mặt nạ dự đoán (deeplabv3: ảnh · ground truth · dự đoán).

2. Kết luận

• **Trên tập nhỏ, pretrain chi phối hơn kiến trúc.** DeepLabV3 đạt 67,11% mIoU trong khi U-Net train từ đầu chỉ 8,88% — khoảng cách này không phải do CNN hay Transformer, mà do đặc trưng có sẵn.

• **SegFormer-B0 nhỏ nhưng cần thời gian.** 3,7M tham số, nhanh gấp 3× mỗi epoch, đạt 37,85% sau 4 epoch — khớp với hạn chế của paper: kết luận của họ đo trên tập lớn, chưa khảo sát vùng ít dữ liệu.

• **Kiểm chứng trước khi kết luận về kiến trúc.** Phép overfit 2 ảnh (mIoU 71,5%) giúp loại trừ khả năng U-Net sai kiến trúc, và chỉ ra giới hạn thật là số epoch.

3. Phụ lục: tái lập

Kết quả trong báo cáo sinh lại được bằng các lệnh sau, mỗi lệnh ghi kết quả vào thư mục *results/* tương ứng:

```
python scripts/prepare_voc2012.py
python A2/run_all.py
python A2/make_demo.py
python reports/build_report.py
```

Mỗi lần chạy lưu *metrics.json* (cấu hình, số tham số, accuracy, thời gian), *history.csv* (loss/accuracy từng epoch) và các hình PNG. Seed cố định 42.

Khai báo sử dụng công cụ AI

Theo mục 1.6 của đề, tôi khai báo phạm vi đã sử dụng công cụ AI hỗ trợ trong bài tập này: đọc và tóm tắt đề; gợi ý bố cục thư mục và các API PyTorch phù hợp; soạn bản nháp ban đầu cho phần lớn mã nguồn trong *common/*, *E1/–E3/*, *A1/*, *A2/*; gợi ý dàn ý và cách trình bày báo cáo; gợi ý cách chẩn đoán một số lỗi shape và lỗi huấn luyện.

Phần tôi trực tiếp thực hiện: cài đặt môi trường và tải toàn bộ dữ liệu; chạy toàn bộ thí nghiệm trên máy của mình; kiểm tra sự nhất quán của từng bảng số và từng hình trong báo cáo với *metrics.json* mà các script sinh ra.